

Project SML

Octa Syahira

2026-06-04

Table of Contents

1. DESKRIPSI DATASET	2
2. PERSIAPAN DATA	2
2.1 Instalasi Package.....	2
2.2 Pemanggilan Package.....	2
2.3 Import Data.....	3
2.4 Eksplorasi Data.....	3
2.5 Transformasi Variabel Kategorik.....	5
2.6 Pemeriksaan Missing Value.....	5
2.7 Pemilihan Variabel Clustering.....	5
2.8 Standardisasi Data	6
3. ANALISIS HIERARCHICAL CLUSTERING	6
3.1 Perhitungan Jarak Euclidean.....	6
3.2 Pembentukan Hierarchical Clustering.....	7
3.3 Dendrogram Hierarchical Clustering.....	7
3.4 Penentuan Jumlah Cluster Optimal	8
3.5 Grafik Average Silhouette Width.....	8
3.6 Pembentukan Cluster Akhir	9
3.7 Dendrogram Cluster Optimal	10
3.8 Visualisasi Cluster	11
3.9 Evaluasi Silhouette	11
3.10 Karakteristik Cluster.....	13
3.11 Boxplot Karakteristik Cluster.....	14
3.12 Penyimpanan Hasil.....	15

1. DESKRIPSI DATASET

Dataset yang digunakan dalam penelitian ini adalah Glass Identification Dataset yang diperoleh dari UCI Machine Learning Repository. Dataset tersebut berisi informasi mengenai karakteristik fisik dan komposisi kimia berbagai jenis kaca yang digunakan untuk mengidentifikasi kategori kaca berdasarkan unsur-unsur penyusunnya.

Dataset terdiri atas 214 observasi dan 10 variabel, yaitu sembilan variabel numerik dan satu variabel kategorik. Variabel numerik yang digunakan meliputi RI (Refractive Index), Na (Sodium), Mg (Magnesium), Al (Aluminium), Si (Silicon), K (Potassium), Ca (Calcium), Ba (Barium), dan Fe (Iron). Sementara itu, variabel Type menunjukkan jenis kaca dan digunakan sebagai informasi tambahan.

Tujuan analisis ini adalah mengelompokkan sampel kaca berdasarkan kemiripan karakteristik fisik dan kandungan unsur kimianya menggunakan metode Hierarchical Clustering.

2. PERSIAPAN DATA

2.1 Instalasi Package

Tahap awal analisis dilakukan dengan memastikan package yang diperlukan telah terinstal, yaitu tidyverse, cluster, dan factoextra. Package tersebut digunakan untuk pengolahan data, pembentukan cluster, serta visualisasi hasil analisis. Setelah terinstal, package dipanggil menggunakan fungsi library() sebelum proses analisis dilakukan.

2.2 Pemanggilan Package

Setelah package terinstal, package dipanggil ke dalam lingkungan kerja R.

```
library(tidyverse)

## Warning: package 'tidyverse' was built under R version 4.5.3
## Warning: package 'ggplot2' was built under R version 4.5.3
## Warning: package 'tidyr' was built under R version 4.5.2
## Warning: package 'readr' was built under R version 4.5.2
## Warning: package 'dplyr' was built under R version 4.5.2
## Warning: package 'stringr' was built under R version 4.5.2

## — Attaching core tidyverse packages ————— tidyverse 2.
0.0 —
## ✓ dplyr      1.2.0      ✓ readr      2.2.0
## ✓ forcats   1.0.1      ✓ stringr    1.6.0
## ✓ ggplot2    4.0.2      ✓ tibble     3.3.0
## ✓ lubridate 1.9.4      ✓ tidyr      1.3.2
```

```
## ✓ purrr      1.1.0
## — Conflicts ————— tidyverse_conflict
s() —
## ✗ dplyr::filter() masks stats::filter()
## ✗ dplyr::lag()    masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors

library(cluster)

## Warning: package 'cluster' was built under R version 4.5.3

library(factoextra)

## Warning: package 'factoextra' was built under R version 4.5.3

## Welcome to factoextra!
## Want to learn more? See two factoextra-related books at https://www.datanova.com/en/product/practical-guide-to-principal-component-methods-in-r/
```

Pemanggilan package dilakukan agar seluruh fungsi yang diperlukan selama analisis dapat digunakan.

2.3 Import Data

Dataset diimpor ke dalam R menggunakan fungsi `read.csv()`.

```
glass <- read.csv(
  "C:/Users/LENOVO/OneDrive/Documents/glass (1).csv"
)
```

Data yang telah berhasil diimpor disimpan ke dalam objek bernama `glass`.

2.4 Eksplorasi Data

Eksplorasi data dilakukan untuk mengetahui struktur dan karakteristik awal dataset.

```
head(glass)

##      RI      Na      Mg      Al      Si      K      Ca      Ba      Fe      Type
## 1 1.52101 13.64 4.49 1.10 71.78 0.06 8.75 0 0.00 1
## 2 1.51761 13.89 3.60 1.36 72.73 0.48 7.83 0 0.00 1
## 3 1.51618 13.53 3.55 1.54 72.99 0.39 7.78 0 0.00 1
## 4 1.51766 13.21 3.69 1.29 72.61 0.57 8.22 0 0.00 1
## 5 1.51742 13.27 3.62 1.24 73.08 0.55 8.07 0 0.00 1
## 6 1.51596 12.79 3.61 1.62 72.97 0.64 8.07 0 0.26 1

str(glass)

## 'data.frame':    214 obs. of  10 variables:
##  $ RI      : num  1.52 1.52 1.52 1.52 1.52 ...
##  $ Na      : num  13.6 13.9 13.5 13.2 13.3 ...
##  $ Mg      : num  4.49 3.6 3.55 3.69 3.62 3.61 3.6 3.61 3.58 3.6 ...
```

```
## $ Al : num 1.1 1.36 1.54 1.29 1.24 1.62 1.14 1.05 1.37 1.36 ...
## $ Si : num 71.8 72.7 73 72.6 73.1 ...
## $ K : num 0.06 0.48 0.39 0.57 0.55 0.64 0.58 0.57 0.56 0.57 ...
## $ Ca : num 8.75 7.83 7.78 8.22 8.07 8.07 8.17 8.24 8.3 8.4 ...
## $ Ba : num 0 0 0 0 0 0 0 0 0 0 ...
## $ Fe : num 0 0 0 0 0 0.26 0 0 0 0.11 ...
## $ Type: int 1 1 1 1 1 1 1 1 1 1 ...
```

```
summary(glass)
```

```
##           RI           Na           Mg           Al
## Min.      :1.511   Min.      :10.73   Min.      :0.000   Min.      :0.290
## 1st Qu.:1.517   1st Qu.:12.91   1st Qu.:2.115   1st Qu.:1.190
## Median :1.518   Median :13.30   Median :3.480   Median :1.360
## Mean     :1.518   Mean     :13.41   Mean     :2.685   Mean     :1.445
## 3rd Qu.:1.519   3rd Qu.:13.82   3rd Qu.:3.600   3rd Qu.:1.630
## Max.     :1.534   Max.     :17.38   Max.     :4.490   Max.     :3.500
##           Si           K           Ca           Ba
## Min.      :69.81   Min.      :0.0000   Min.      : 5.430   Min.      :0.000
## 1st Qu.:72.28   1st Qu.:0.1225   1st Qu.: 8.240   1st Qu.:0.000
## Median :72.79   Median :0.5550   Median : 8.600   Median :0.000
## Mean     :72.65   Mean     :0.4971   Mean     : 8.957   Mean     :0.175
## 3rd Qu.:73.09   3rd Qu.:0.6100   3rd Qu.: 9.172   3rd Qu.:0.000
## Max.     :75.41   Max.     :6.2100   Max.     :16.190   Max.     :3.150
##           Fe           Type
## Min.      :0.00000   Min.      :1.00
## 1st Qu.:0.00000   1st Qu.:1.00
## Median :0.00000   Median :2.00
## Mean     :0.05701   Mean     :2.78
## 3rd Qu.:0.10000   3rd Qu.:3.00
## Max.     :0.51000   Max.     :7.00
```

```
dim(glass)
```

```
## [1] 214 10
```

```
names(glass)
```

```
## [1] "RI" "Na" "Mg" "Al" "Si" "K" "Ca" "Ba" "Fe" "Type"
```

Berdasarkan hasil eksplorasi, dataset terdiri atas 214 observasi dan 10 variabel. Seluruh variabel prediktor bertipe numerik, sedangkan variabel Type menunjukkan kategori jenis kaca.

Variabel RI memiliki nilai minimum sebesar 1,511, nilai maksimum sebesar 1,534, dan rata-rata sebesar 1,518. Variabel Na memiliki rata-rata sebesar 13,41, sedangkan Mg memiliki rata-rata sebesar 2,69.

Variabel Si memiliki rata-rata sebesar 72,65 dengan rentang nilai antara 69,81 hingga 75,41. Selain itu, variabel K memiliki nilai maksimum sebesar 6,21, jauh lebih besar

dibandingkan nilai rata-ratanya yaitu 0,497, yang menunjukkan adanya beberapa sampel dengan kandungan kalium yang sangat tinggi.

Dataset memiliki nama variabel sebagai berikut:

```
names(glass)
## [1] "RI" "Na" "Mg" "Al" "Si" "K" "Ca" "Ba" "Fe" "Type"
```

Jumlah observasi dan variabel ditunjukkan oleh:

```
dim(glass)
## [1] 214 10
```

yang menghasilkan:

214 observasi 10 variabel

2.5 Transformasi Variabel Kategorik

Variabel Type diubah menjadi factor agar dikenali sebagai variabel kategorik.

```
glass$Type <- as.factor(glass$Type)
```

Transformasi ini dilakukan karena variabel Type merupakan label kategori dan tidak digunakan dalam proses pembentukan cluster.

2.6 Pemeriksaan Missing Value

Pemeriksaan missing value dilakukan untuk memastikan tidak terdapat data yang hilang.

```
sum(is.na(glass))
## [1] 0
```

Hasil pemeriksaan menunjukkan nilai 0, sehingga dapat disimpulkan bahwa seluruh data tersedia secara lengkap dan tidak memerlukan proses penanganan missing value.

2.7 Pemilihan Variabel Clustering

Variabel Type tidak digunakan dalam proses clustering karena merupakan label kategori.

```
glass_clust <- glass %>%
  select(
    RI, Na, Mg, Al,
    Si, K, Ca, Ba, Fe
  )
```

Dengan demikian, analisis clustering hanya menggunakan sembilan variabel numerik.

2.8 Standardisasi Data

Karena setiap variabel memiliki satuan dan rentang nilai yang berbeda, maka dilakukan standardisasi data menggunakan metode z-score.

```
glass_scale <- scale(glass_clust)
summary(glass_scale)
```

##	RI	Na	Mg	Al
##	Min. : -2.3759	Min. : -3.2793	Min. : -1.8611	Min. : -2.3132
##	1st Qu.: -0.6068	1st Qu.: -0.6127	1st Qu.: -0.3948	1st Qu.: -0.5106
##	Median : -0.2257	Median : -0.1321	Median : 0.5515	Median : -0.1701
##	Mean : 0.0000	Mean : 0.0000	Mean : 0.0000	Mean : 0.0000
##	3rd Qu.: 0.2608	3rd Qu.: 0.5108	3rd Qu.: 0.6347	3rd Qu.: 0.3707
##	Max. : 5.1252	Max. : 4.8642	Max. : 1.2517	Max. : 4.1162
##	Si	K	Ca	Ba
##	Min. : -3.6679	Min. : -0.76213	Min. : -2.4783	Min. : -0.3521
##	1st Qu.: -0.4789	1st Qu.: -0.57430	1st Qu.: -0.5038	1st Qu.: -0.3521
##	Median : 0.1795	Median : 0.08884	Median : -0.2508	Median : -0.3521
##	Mean : 0.0000	Mean : 0.00000	Mean : 0.0000	Mean : 0.0000
##	3rd Qu.: 0.5636	3rd Qu.: 0.17318	3rd Qu.: 0.1515	3rd Qu.: -0.3521
##	Max. : 3.5622	Max. : 8.75961	Max. : 5.0824	Max. : 5.9832
##	Fe			
##	Min. : -0.5851			
##	1st Qu.: -0.5851			
##	Median : -0.5851			
##	Mean : 0.0000			
##	3rd Qu.: 0.4412			
##	Max. : 4.6490			

Hasil standardisasi menunjukkan bahwa seluruh variabel memiliki rata-rata mendekati nol dan simpangan baku mendekati satu. Standardisasi diperlukan agar seluruh variabel memiliki kontribusi yang seimbang dalam perhitungan jarak.

3. ANALISIS HIERARCHICAL CLUSTERING

3.1 Perhitungan Jarak Euclidean

Jarak antar objek dihitung menggunakan metode Euclidean Distance.

```
d <- dist(
  glass_scale,
  method = "euclidean"
)
```

Jarak Euclidean digunakan untuk mengukur tingkat kemiripan antar sampel berdasarkan seluruh variabel numerik yang digunakan.

3.2 Pembentukan Hierarchical Clustering

Proses clustering dilakukan menggunakan metode Ward.D2.


```
hc <- hclust(  
  d,  
  method = "ward.D2"  
)
```

Metode Ward dipilih karena mampu menghasilkan kelompok yang relatif homogen dengan meminimalkan variasi di dalam cluster.

3.3 Dendrogram Hierarchical Clustering

Hasil hierarchical clustering divisualisasikan menggunakan dendrogram.

```
fviz_dend(  
  hc,  
  show_labels = FALSE,  
  main = "Dendrogram Hierarchical Clustering"  
)
```



Berdasarkan dendrogram hierarchical clustering, terlihat bahwa data Glass membentuk beberapa kelompok yang berbeda. Sebagian besar penggabungan objek terjadi pada nilai Height yang rendah (<10), menunjukkan tingkat kemiripan yang tinggi antar sampel dalam kelompok yang sama. Sementara itu, penggabungan cluster utama terjadi pada Height yang relatif tinggi (sekitar 20–27), yang menandakan adanya perbedaan

karakteristik yang cukup signifikan antar kelompok. Apabila dendrogram dipotong pada Height 15, data dapat dikelompokkan menjadi sekitar 4–5 cluster utama. Hasil ini menunjukkan bahwa dataset Glass memiliki struktur cluster yang cukup baik sehingga metode hierarchical clustering mampu mengidentifikasi pola pengelompokan berdasarkan karakteristik kimia kaca.

3.4 Penentuan Jumlah Cluster Optimal

Jumlah cluster optimal ditentukan menggunakan metode Average Silhouette Width.

```
sil_width <- c()

for(k in 2:10){

  cluster_k <- cutree(
    hc,
    k = k
  )

  sil <- silhouette(
    cluster_k,
    d
  )

  sil_width[k] <- mean(
    sil[,3]
  )
}
```


Hasil perhitungan silhouette disajikan sebagai berikut.

```
hasil_silhouette <- data.frame(
  Cluster = 2:10,
  Silhouette = sil_width[2:10]
)
```

Berdasarkan hasil tersebut, nilai silhouette tertinggi diperoleh pada 4 cluster dengan nilai 0,4523, sehingga jumlah cluster optimal ditetapkan sebanyak empat cluster.

3.5 Grafik Average Silhouette Width

```
plot(
  2:10,
  sil_width[2:10],
  type = "b",
  pch = 19,
  xlab = "Jumlah Cluster",
  ylab = "Average Silhouette Width",
  main = "Pemilihan Jumlah Cluster Optimal"
)
```

Berdasarkan metode Silhouette, jumlah cluster optimal pada dataset Glass adalah 4 cluster dengan nilai Average Silhouette Width sekitar 0,45.

3.6 Pembentukan Cluster Akhir

Jumlah cluster optimal yang diperoleh kemudian digunakan untuk membentuk cluster akhir.

```
best_k <- hasil_silhouette$Cluster[
  which.max(
    hasil_silhouette$Silhouette
  )
]

best_k

## [1] 4

cluster_final <- cutree(
  hc,
  k = best_k
)
```

Distribusi anggota cluster adalah sebagai berikut.


```
table(cluster_final)
```

```
## cluster_final
##   1   2   3   4
## 175 10 27  2
```

Cluster 1 merupakan cluster terbesar dengan proporsi sekitar 81,8% dari seluruh data.

3.7 Dendrogram Cluster Optimal

```
fviz_dend(
  hc,
  k = best_k,
  rect = TRUE,
  rect_fill = TRUE,
  show_labels = FALSE,
  main = paste(
    "Dendrogram dengan",
    best_k,
    "Cluster"
  )
)
```




Berdasarkan dendrogram, data Glass dapat dikelompokkan menjadi 4 cluster yang berbeda. Penggabungan cluster terjadi pada nilai Height yang relatif tinggi, menunjukkan adanya perbedaan karakteristik yang cukup jelas antar kelompok. Sebagian besar objek berada pada satu cluster besar, sedangkan cluster lainnya memiliki anggota yang lebih sedikit. Hasil ini menunjukkan bahwa dataset Glass

memiliki struktur pengelompokan yang cukup baik dan dapat dibedakan berdasarkan kemiripan karakteristiknya.

3.8 Visualisasi Cluster

```
fviz_cluster(  
  list(  
    data = glass_scale,  
    cluster = cluster_final  
  ),  
  geom = "point",  
  ellipse.type = "convex",  
  ggtheme = theme_minimal()  
)
```



Plot cluster menunjukkan bahwa data terbagi menjadi 4 kelompok yang berbeda. Sebagian besar objek berada pada cluster 1, sedangkan cluster 2, 3, dan 4 memiliki jumlah anggota yang lebih sedikit. Jarak antar cluster yang cukup jelas menunjukkan bahwa hasil pengelompokan sudah cukup baik dalam membedakan karakteristik data Glass.

3.9 Evaluasi Silhouette

```
sil_final <- silhouette(  
  cluster_final,  
  d  
)
```

```
fviz_silhouette(
  sil_final
)

##   cluster size ave.sil.width
## 1         1  175         0.48
## 2         2   10         0.19
## 3         3   27         0.36
## 4         4    2         0.97
```



Hasil evaluasi menggunakan metode silhouette menunjukkan bahwa pembentukan 4 cluster menghasilkan nilai average silhouette width sebesar 0,45. Nilai ini mengindikasikan bahwa struktur cluster yang terbentuk sudah cukup baik karena sebagian besar observasi memiliki nilai silhouette positif. Namun, masih terdapat beberapa observasi dengan nilai silhouette rendah atau negatif yang menunjukkan adanya tumpang tindih antar cluster. Secara umum, pengelompokan data Glass mampu membedakan karakteristik objek dengan cukup baik, meskipun pemisahan antar beberapa cluster belum sepenuhnya optimal.

Nilai silhouette rata-rata keseluruhan diperoleh sebesar:

```
mean(
  sil_final[,3]
)

## [1] 0.4523495
```

Nilai tersebut menunjukkan bahwa hasil clustering memiliki kualitas yang cukup baik karena objek dalam setiap cluster relatif lebih mirip dengan anggota cluster yang sama dibandingkan cluster lainnya.

3.10 Karakteristik Cluster

Karakteristik cluster dianalisis menggunakan nilai rata-rata masing-masing variabel.

```
glass_clustered <- cbind(
  glass_clust,
  Cluster = factor(cluster_final)
)

karakteristik_cluster <- aggregate(
  . ~ Cluster,
  data = glass_clustered,
  mean
)

karakteristik_cluster
```

##	Cluster	RI	Na	Mg	Al	Si	K	C
## 1	1	1.518276	13.26034	3.2143429	1.325886	72.66789	0.4849714	8.834000
## 2	2	1.526123	12.66200	0.1010000	1.199000	71.88500	0.2030000	13.437000
## 3	3	1.516459	14.66963	0.4062963	2.190000	72.97741	0.2611111	8.243704
## 4	4	1.513185	13.01000	0.0000000	3.030000	70.59000	6.2100000	6.945000

##		Ba	Fe
## 1	0.01548571	0.06348571	
## 2	0.31500000	0.07000000	
## 3	1.17037037	0.01444444	
## 4	0.00000000	0.00000000	


- Cluster 1 Cluster 1 terdiri atas 175 observasi dan memiliki rata-rata Mg sebesar 3,21 serta Ca sebesar 8,83. Cluster ini mewakili kelompok kaca dengan karakteristik yang paling mendekati rata-rata keseluruhan data.
- Cluster 2 Cluster 2 terdiri atas 10 observasi dengan nilai RI tertinggi (1,526) dan kandungan Ca yang sangat tinggi (13,44). Kandungan Mg pada cluster ini hampir tidak ada.
- Cluster 3 Cluster 3 terdiri atas 27 observasi dengan kandungan Na (14,67), Al (2,19), dan Ba (1,17) yang relatif tinggi dibandingkan cluster lainnya.

- Cluster 4 Cluster 4 hanya terdiri atas 2 observasi dan memiliki kandungan K yang sangat tinggi (6,21) serta kandungan Mg sebesar 0. Karakteristik tersebut menyebabkan cluster ini terpisah jauh dari cluster lainnya.

3.11 Boxplot Karakteristik Cluster

```
glass_long <- glass_clustered %>%
  pivot_longer(
    cols = -Cluster,
    names_to = "Variabel",
    values_to = "Nilai"
  )
```

```
ggplot(
  glass_long,
  aes(
    x = Cluster,
    y = Nilai,
    fill = Cluster
  )
) +
  geom_boxplot() +
  facet_wrap(
    ~Variabel,
    scales = "free"
  ) +
  theme_bw()
```



Berdasarkan boxplot karakteristik cluster, terdapat perbedaan komposisi kimia yang cukup jelas antar kelompok. Cluster 1 memiliki karakteristik yang mendekati rata-rata data, Cluster 2 ditandai oleh nilai Ca dan RI yang tinggi, Cluster 3 memiliki nilai Na, Al, dan Si yang relatif lebih tinggi, sedangkan Cluster 4 menunjukkan karakteristik khusus dengan nilai K yang jauh lebih tinggi dibandingkan cluster lainnya. Secara umum, variabel K, Ca, Na, Al, RI, dan Si merupakan variabel yang paling membedakan antar cluster.

3.12 Penyimpanan Hasil

```
write.csv(  
  glass,  
  "hasil_clustering_glass.csv",  
  row.names = FALSE  
)
```

Hasil pengelompokan disimpan dalam file `hasil_clustering_glass.csv` yang memuat data Glass beserta label cluster masing-masing observasi. Penyimpanan ini bertujuan untuk memudahkan analisis dan penggunaan hasil clustering pada tahap selanjutnya.